

ОГЛАВЛЕНИЕ

ВВЕДЕНИЕ	3
1. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ	4
1.1. ВВЕДЕНИЕ В ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ . . .	4
1.1.1. УСТРОЙСТВО ПРОСТОЙ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ	5
1.1.2. ОБУЧЕНИЕ С УЧИТЕЛЕМ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ	6
1.2. ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ В ОБРАБОТКЕ ЕСТЕСТВЕННОГО ЯЗЫКА	9
1.2.1. ВЕКТОРНОЕ ПРЕДСТАВЛЕНИЕ ТЕКСТА	9
1.3. АРХИТЕКТУРА ТРАНСФОРМЕР И ЕЕ РОЛЬ В ДИАЛОГОВЫХ МОДЕЛЯХ	10
1.3.1. МЕХАНИЗМ ВНИМАНИЯ	11
1.3.2. МОДЕЛЬ T5: АРХИТЕКТУРА И ЕЕ ОСОБЕННОСТИ .	11
1.3.3. FLAN	11
1.4. ПОСТАНОВКА ЗАДАЧИ ДИАЛОГОВОЙ СИСТЕМЫ	12
2. СБОР ДАННЫХ И СОЗДАНИЕ ДИАЛОГОВОЙ ЧАСТИ НАБОРА ДАННЫХ	13
2.1. СТРУКТУРА НАБОРА ДАННЫХ	13
2.2. СБОР ДАННЫХ	13
2.2.1. СБОР И ПРЕДОБРАБОТКА ПЕРВОНАЧАЛЬНЫХ ДАННЫХ	13
2.2.2. ПОСТОБРАБОТКА ПЕРВОНАЧАЛЬНЫХ ДАННЫХ .	14
3. СИНТЕЗ ОПИСАНИЙ NPC И АНАЛИЗ НАБОРА ДАННЫХ . .	15
3.1. ПОЛУЧЕНИЕ ОПИСАНИЙ NPC	15
3.2. АНАЛИЗ DNDD	17
4. ПОДГОТОВКА НАБОРА ДАННЫХ DNDD ДЛЯ ОБУЧЕНИЯ МОДЕЛЕЙ	20
4.1. ЭМУЛЯЦИЯ ДИАЛОГОВЫХ ВЗАИМОДЕЙСТВИЙ	20

4.2. СТРУКТУРИРОВАНИЕ ВХОДНЫХ ДАННЫХ ДЛЯ ОБУЧЕНИЯ	20
4.3. ОПТИМИЗАЦИЯ ДАННЫХ ПОД ПОТРЕБИТЕЛЬСКОЕ ОБО- РУДОВАНИЕ	21
5. ОБУЧЕНИЕ МОДЕЛИ	23
5.1. ПОИСК ОПТИМАЛЬНОЙ МОДЕЛИ	23
5.2. ПОИСК ОПТИМАЛЬНЫХ ГИПЕРПАРАМЕТРОВ ДЛЯ МО- ДЕЛИ	23
5.2.1. ПОСТАНОВКА ЗАДАЧИ	23
5.2.2. АНАЛИЗ РЕЗУЛЬТАТОВ ЭКСПЕРИМЕНТОВ С ГИ- ПЕРПАРАМЕТРАМИ	24
5.3. ОБУЧЕНИЕ ИТОГОВОЙ МОДЕЛИ	28
ЗАКЛЮЧЕНИЕ	31
СПИСОК ЛИТЕРАТУРЫ	32
ПРИЛОЖЕНИЕ А. ПРИМЕР ТРАНСЛЯЦИИ ИЗ ЯЗЫКА D В JSON	34
ПРИЛОЖЕНИЕ Б. ИСХОДНЫЙ КОД ОБРАБОТКИ DNDD	46
ПРИЛОЖЕНИЕ В. ПРИМЕР ДИАЛОГА	61

ВВЕДЕНИЕ

В настоящее время разработка диалоговых систем является важным направлением машинного обучения, в условиях растущей автоматизации взаимодействия человека с компьютером. Такие технологии могут быть использованы в различных отраслях, включая игровую. Недавние достижения в глубоком обучении позволяют создавать диалоговые модели, которые способны обрабатывать естественный язык и предоставлять пользователю качественные ответы на запросы. Для успешного обучения таких моделей необходимы качественные наборы данных, содержащие диалоги между участниками.

Целью работы является создание диалоговой модели, которая будет способна генерировать ответы на основе образа неигрового персонажа и контекста диалога. В данной работе рассматривается процесс создания и анализа набора данных DNDD (Dungeon & Dragons Dialogues) с использованием текущих больших языковых моделей для обучения диалоговой модели, основанный на сборе и предобработке данных из различных источников с учетом образа неигровых персонажей. Такая модель позволит улучшить игровой опыт игроков, сделать этот опыт более иммерсивным. В данной работе также рассматривается процесс подготовки набора данных для обучения модели, формулирование задачи для моделирования, поиск оптимальной модели и параметров для успешного и эффективного обучения.

1. ТЕОРЕТИЧЕСКАЯ ЧАСТЬ

1.1. ВВЕДЕНИЕ В ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ

Обработка естественного языка является крайне тяжелой задачей для моделирования стандартными алгоритмами. Машинное обучение позволяет решать задачи на основе статистических наблюдений из данных без явной алгоритмизации решения задачи. Недавние прорывы в области обработки естественного языка показывают, что методами машинного обучения можно частично или сполна выполнять многие человеческие задачи, например, краткое изложение текста, написание кода, общение с собеседником и другие, а также добиться результатов распознавания речи сопоставимых с результатами человека [1, 2].

Одним из основных аспектов машинного обучения является искусственная нейронная сеть (далее ИНС), созданная по подобию биологических нейронных сетей. Модель ИНС – описание сети, математическая модель, часто представляемая в виде графа, нацеленная на решение задачи прогнозирования на основе обучающей выборки данных. Методами настройки параметров моделей под конкретную задачу называют методами обучения. Такими методами являются: обучение с учителем, обучение без учителя и обучение с подкреплением.

Каждый метод имеет свои особенности и применяется в зависимости от ситуации. Например, обычно обучение с учителем применяется в тех случаях, когда обучающий набор данных размечен на основе некоторых критериев. Такие задачи обычно являются задачами классификации, когда каждый экземпляр выборки имеет один или больше собственный класс. Такой подход имеет ограничения: как правило количество размеченных данных значительно меньше общего количество данных. В ситуациях, когда данные не размечены, применяется обучение без учителя. Благодаря такому подходу, можно обучить модель делить данные на кластеры, генерировать текст, изображения и т.д. Когда модели приходится принимать решения как интеллектуальный агент в условиях данной ей среды и соответствующих откликов среды на решения, применяется метод обучения с подкреплением. Для построения мощных современных цифровых ассистентов могут использоваться все три подхода к обучению мо-

делей, используя модели, полученных конкретным методом, в качестве промежуточных или вспомогательных, для обучения конечной модели [3].

1.1.1. УСТРОЙСТВО ПРОСТОЙ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ

Устройство простой ИНС можно описать как взвешенный набор узлов, разделенный на слои, соединенные между собой активационными функциями φ . Функциям активации желательно иметь свойства: нелинейность, непрерывная дифференцируемость, бесконечная область значений, монотонность. При построении модели ИНС в качестве активационных функций часто используется одна из следующих функций:

1. Гиперболический тангенс:

$$\varphi(z) = \frac{e^{2z} - 1}{e^{2z} + 1}. \quad (1.1)$$

2. Функция ReLU:

$$\varphi(z) = \max(0, z). \quad (1.2)$$

3. Функция GELU:

$$\varphi(z) = \frac{1}{2}z \left[1 + \operatorname{erf} \left(z/\sqrt{2} \right) \right]. \quad (1.3)$$

4. Логистическая функция (сигмоида):

$$\varphi(z) = \frac{1}{1 + e^{-z}}. \quad (1.4)$$

5. Многопеременная логистическая функция (softmax):

$$\varphi(z)_i = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}. \quad (1.5)$$

Архитектуры ИНС могут сильно отличаться друг от друга в зависимости от поставленных задач и требований к качеству предсказаний модели. Раздел, который занимается изучением ИНС с большим количеством скрытых слоев, т.е. тех слоев, которые находятся между входным и выходным, называется глубоким обучением, а такие модели называются глубокими. Примером такой

архитектуры модели может служить трансформер [4], речь о котором пойдет дальше.

Набор весов W и отклонений b являются параметрами модели, обозначаемые как θ . Прогноз или функция гипотезы модели ИНС обозначается как h_θ . $W^{[l]}$, $b^{[l]}$, $h_\theta^{[l]}$ – веса, отклонения и выход модели на l -ом слое. Описать работу обобщенной модели ИНС с L слоями можно следующим образом:

1. $h_\theta^{[0]} = x$.
2. $h_\theta^{[l]} = \varphi \circ \left(W^{[l-1]} h_\theta^{[l-1]}(x) + b^{[l-1]} \right)$, где $1 \leq l \leq L - 1$.
3. $h_\theta = h_\theta^{[L]} = W^{[L-1]} h_\theta^{[L-1]}(x) + b^{[L-1]}$.

Примером простой ИНС может являться однослойный перцептрон. Схема однослойного перцептрона представлена на рис. 1.1.

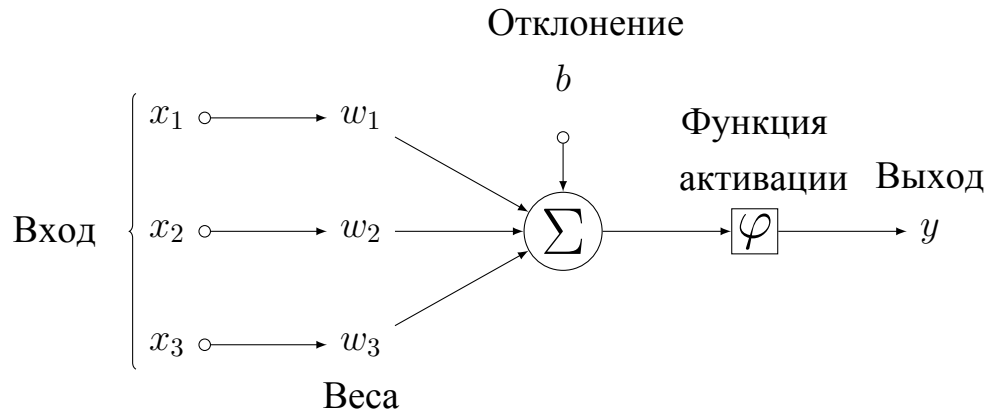


Рисунок 1.1 – Однослойный перцептрон

1.1.2. ОБУЧЕНИЕ С УЧИТЕЛЕМ ИСКУССТВЕННОЙ НЕЙРОННОЙ СЕТИ

Как было сказано ранее, для того, чтобы обучить ИНС с учителем, требуется иметь такой набор данных, где каждый элемент имел соответствующую метку класса. Элементы набора данных, т.е. входные данные, принадлежат некоторому входному пространству \mathcal{X} , например, картинкам кошек, а метки принадлежат к выходному пространству \mathcal{Y} , например, породе кошек. Из такого набора данных \mathcal{D} мы строим тренировочную подвыборку, состоящую из пар, элементов:

$$\mathcal{D}_{\text{train}} = \{ (x_i, \hat{y}_i) \mid x_i \in \mathcal{X}, \hat{y}_i \in \mathcal{Y}, i = \overline{1, \dots, n}, n \leq |\mathcal{D}| \}. \quad (1.6)$$

Мы стремимся получить целевую функцию ИНС h_{θ^*} с оптимальным набором параметров θ^* на основе $\mathcal{D}_{\text{train}}$, при котором h_{θ^*} наиболее эффективно отображает из пространства \mathcal{X} в пространство \mathcal{Y} . Для определения того, насколько эффективно предсказывает модель, требуется иметь неотрицательную функцию $\ell : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+$, которая измеряет ошибку предсказания $h_{\theta}(x)$ по отношению к истинной метке \hat{y} . Такие функции, как правило, называются функциями ошибки или функциями потерь. Функция потерь выбирается исходя из условий конкретной задачи, но часто является одной из следующих функций:

1. Функция потерь L_1 :

$$\ell(h_{\theta}(x), \hat{y}) = |\hat{y} - h_{\theta}(x)|. \quad (1.7)$$

2. Функция потерь L_2 :

$$\ell(h_{\theta}(x), \hat{y}) = (\hat{y} - h_{\theta}(x))^2. \quad (1.8)$$

3. Функция потерь перекрестной энтропии:

$$\ell(h_{\theta}(x), \hat{y}) = -\hat{y} \log h_{\theta}(x). \quad (1.9)$$

4. Функция потерь NLL:

$$\ell(h_{\theta}(x), \hat{y}) = -[\hat{y} \log h_{\theta}(x) + (1 - \hat{y}) \log(1 - h_{\theta}(x))]. \quad (1.10)$$

Обучение модели с учителем сводится к задаче минимизации функции потерь по тренировочной выборке:

$$\mathcal{L}_{\mathcal{D}_{\text{train}}}(\theta) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{i=1}^{|\mathcal{D}_{\text{train}}|} \ell(h_{\theta}(x_i), \hat{y}_i) \rightarrow \min_{\theta}. \quad (1.11)$$

Чтобы решить такую задачу минимизации функции потерь по тренировочной выборке, требуется вычислить:

$$\frac{\partial \mathcal{L}_{\mathcal{D}_{\text{train}}}(\theta)}{\partial \theta}. \quad (1.12)$$

Метод, который позволяет аналитически вычислить градиент (1.12) в точке, называется методом обратного распространения ошибки [5]. Основа метода – автоматическое построение графа вычислений и правило вычисления производной сложной функции. С полученным градиентом функции потерь параметры модели ИНС меняются алгоритмом оптимизации. Одними из важных составляющих алгоритмов оптимизации являются выбор размера шага оптимизатора η , называемым еще скоростью обучения, и планировщик скорости обучения ς , поскольку влияют на скорость процесса обучения и на преодоления методом оптимизации локальных минимумов. Частым выбором таких алгоритмов являются: «GD» (градиентный спуск), «SGD» (стохастический градиентный спуск), Adam, AdaFactor [6, 7].

Обучение является итеративным процессом, где итерация или шаг итерации – это обработка моделью одного или нескольких примеров обучающей выборки. Обработка полного набора выборки называют эпохой.

Алгоритм обучения модели ИНС с учителем представлен ниже.

Алгоритм 1 Обучение модели ИНС с учителем

- 1: Инициализировать θ случайно или по некоторому закону распределения.
 - 2: По каждой эпохе из количества эпох:
 - 3: По каждому примеру (x, \hat{y}) из обучающей выборки $\mathcal{D}_{\text{train}}$:
 - 4: Получить предсказание модели $y \leftarrow h_{\theta}(x)$.
 - 5: Получить значение функции потерь $\ell(y, \hat{y})$.
 - 6: Получить градиент $\nabla \ell$ методом обратного распространения.
 - 7: Сделать шаг оптимизации.
 - 8: Аккумулировать значение общей функции потерь $\mathcal{L} \leftarrow \mathcal{L} + \ell(y, \hat{y})$.
-

Однако одной тренировочной подвыборки чаще всего не достаточно для успешного обучения модели. Как правило используют три подвыборки исходных данных \mathcal{D} . Помимо обучающей, используется валидационная \mathcal{D}_{val} , которая используется в конце эпохи обучения, на которой модель не обучается, но проверяется на наборе данных, которые она не видела, для корректировки гиперпараметров модели. Гиперпараметры – это параметры, которые используются для контроля процесса обучения. Примерами гиперпараметров могут служить как вышеупомянутые η и ς , так и количество слоев в модели, активационные функции и т.д. Для оценки итогового качества модели обычно используется тестовая выборка $\mathcal{D}_{\text{test}}$. Методы, которые разбивают исходный набор данных \mathcal{D} на подвыборки, называются методами стратификации.

Хоть ℓ , \mathcal{L} и показывают качество прогнозирования модели h_θ , но на практике анализировать качество модели только по значениям функции потерь – это сложная задача. Помимо функции потерь используются метрики оценки прогнозирования. Выбор метрик сильно зависит от поставленной задачи.

1.2. ИСКУССТВЕННЫЕ НЕЙРОННЫЕ СЕТИ В ОБРАБОТКЕ ЕСТЕСТВЕННОГО ЯЗЫКА

1.2.1. ВЕКТОРНОЕ ПРЕДСТАВЛЕНИЕ ТЕКСТА

Из устройства работы ИНС следует, чтобы данные, на которых обучается модель были численными. Поэтому при обработке текста требуется получить его векторное представление для дальнейшей работы с ним.

Простейшим методом представления слов в векторном пространстве является «*One-Hot Encoding*» (быстрое кодирование). Его суть заключается в присвоении каждому слову из входной последовательности слов вектора, где в позиции, соответствующей слову в словаре размерностью словаря, ставится единица, а во всех остальных позициях – ноль. Словарь содержит весь список возможных слов для кодирования. Размерность такого вектора составляет $1 \times N$, где N – количество слов в словаре. Пример быстрого кодирования показан ниже.

Таблица 1.1 – Пример словаря

Цвет
Красный
Зеленый
Синий

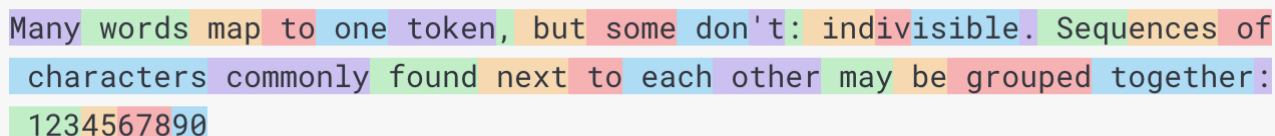
Таблица 1.2 – Пример быстрого кодирования

Красный	Зеленый	Синий
1	0	0
0	1	0
0	0	1

Представлением текстовых данных в численном виде могут заниматься и модели ИНС: учить полезную информацию о входной последовательности, ре-

шая задачу языкового моделирования, кодировать ее в векторном виде для последующего использования на конечной задачи, например, задачи классификации или задачи генерации текста. Одной из первых широко распространенных обученных моделей для кодирования текста является Word2vec [8].

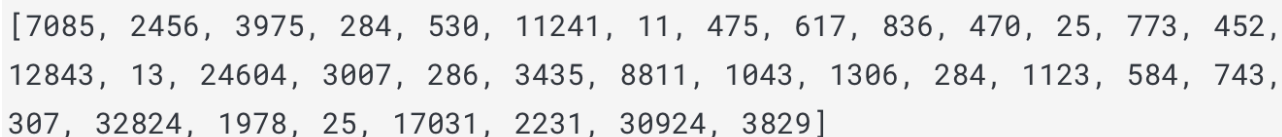
В современных моделях для обработки естественного языка в качестве основы векторного представления данных используют метод, называемый токенизацией. Токенизация – разбиение входного текста на части, называемые токенами. В качестве части текста могут быть как слова целиком, так и части слов. Токенизация представляет входной текст как вектор, состоящий из номеров токенов в общем словаре. Размер закодированной последовательности может зависеть как длиной входной последовательности, так и от требуемой длины, дополняя неиспользуемое пространство специальными токенами. Пример токенизации «Byte-Pair Encoding» (побайтное кодирование) [9] для входной последовательности «Many words map to one token, but some don't: indivisible. Sequences of characters commonly found next to each other may be grouped together: 1234567890» представлен ниже. Токены, на которые разбивает кодировщик входную последовательность, показаны на рис. 1.2.



Many words map to one token, but some don't: indivisible. Sequences of characters commonly found next to each other may be grouped together: 1234567890

Рисунок 1.2 – Пример работы токенизации

Векторное представление такой последовательность токенов показано на рис. 1.3.



[7085, 2456, 3975, 284, 530, 11241, 11, 475, 617, 836, 470, 25, 773, 452, 12843, 13, 24604, 3007, 286, 3435, 8811, 1043, 1306, 284, 1123, 584, 743, 307, 32824, 1978, 25, 17031, 2231, 30924, 3829]

Рисунок 1.3 – Векторное представление токенов

1.3. АРХИТЕКТУРА ТРАНСФОРМЕР И ЕЕ РОЛЬ В ДИАЛОГОВЫХ МОДЕЛЯХ

Стандартным выбором архитектуры модели ИНС при обработке естественного языка является архитектура трансформер. Трансформер состоит из

набора блоков «*encoder*» (кодировщика) и «*decoder*» (декодировщика). Входной текст токенизируется, а к полученному векторному представлению токенов добавляется позиционное кодирование, т.е. информация о позиции токена во входном тексте.

1.3.1. МЕХАНИЗМ ВНИМАНИЯ

PLACEHOLDER

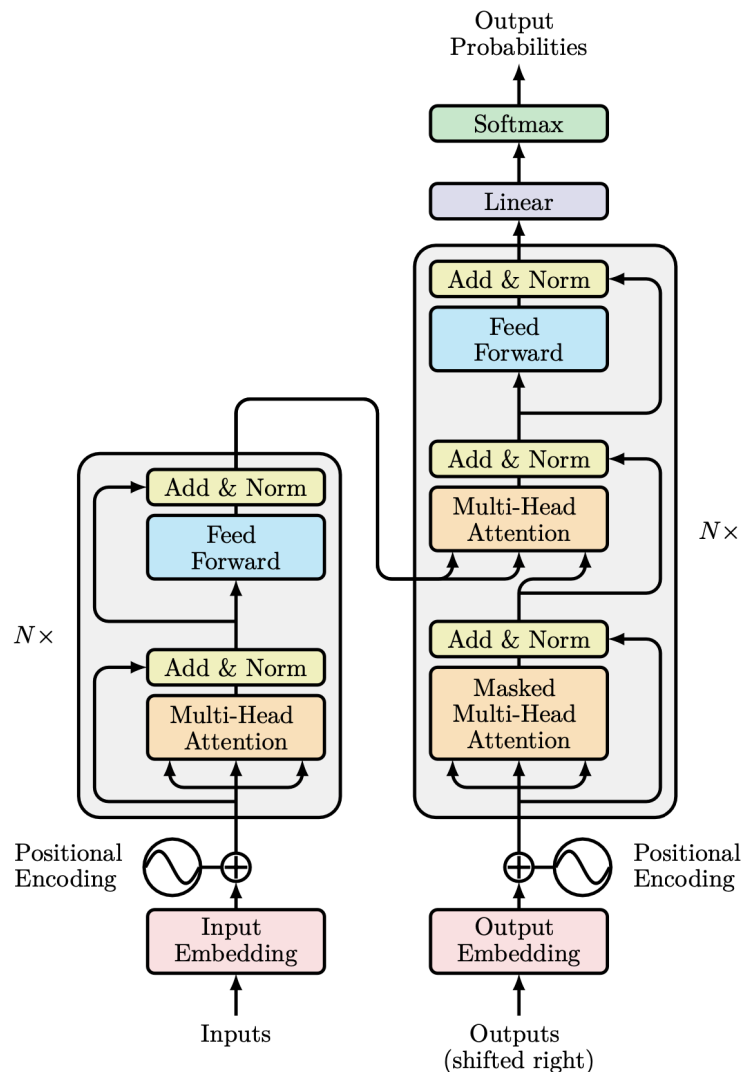


Рисунок 1.4 – Архитектура трансформера

1.3.2. МОДЕЛЬ T5: АРХИТЕКТУРА И ЕЕ ОСОБЕННОСТИ

PLACEHOLDER

1.3.3. FLAN

PLACEHOLDER

1.4. ПОСТАНОВКА ЗАДАЧИ ДИАЛоговой СИСТЕМЫ

PLACEHOLDER

2. СБОР ДАННЫХ И СОЗДАНИЕ ДИАЛоговой ЧАСТИ НАБОРА ДАННЫХ

2.1. СТРУКТУРА НАБОРА ДАННЫХ

Чтобы создать набор данных для обучения диалоговой модели, которая эмулирует поведение неигровых персонажей (далее NPC) по заданному описанию в играх, необходимо иметь диалоги, построенные по определенной системе правил. Одной из самой распространенной, обширной и гибкой системой правил, по которым можно описать NPC, является система *Dungeon & Dragons* (далее D&D), т.к. она обладает вполне определенной структурой. Например, персонажи обязаны иметь конкретное мировоззрение, определяющее их поведение и взгляды на поступки, мотивацию, внешнее описание и слабости. Поэтому выбор такой системы выглядит естественным.

Набор данных, созданный из данных игр во вселенной D&D, должен содержать примеры диалогов NPC с главным героем и примеры описания NPC в формате Name/Alignment/Description/Flaw/Motivation/Personality.

2.2. СБОР ДАННЫХ

2.2.1. СБОР И ПРЕДОБРАБОТКА ПЕРВОНАЧАЛЬНЫХ ДАННЫХ

Первоначальные данные были получены из следующих игр:

1. Baldur's Gate: Enhanced Edition
2. Baldur's Gate 2 - Enhanced Edition
3. Icewind Dale: Enhanced Edition
4. Planescape: Torment: Enhanced Edition

Такой выбор игр неслучаен: все эти игры были созданы с помощью игрового движка *Infinity Engine*. Диалоги были получены следующим образом:

1. Диалоги, которые были использованы, находились в скомпилированном файле, который можно было найти внутри «.bif» файла;

2. Чтобы получить диалоги персонажей в скомпилированном формате с расширением «.dlg», была использована программа WinBif;
3. Далее, с помощью WeiDU, специального транслятора, написанного для создания собственных диалогов в играх Infinity Engine в качестве модификации, эти файлы были преобразованы в формат языка «.d»;
4. Наконец, конвертированы полученные файлы в удобный для анализа JSON-формат, который содержал возможные диалоги персонажей с главным героем.

2.2.2. ПОСТОБРАБОТКА ПЕРВОНАЧАЛЬНЫХ ДАННЫХ

Для начала, полученные JSON файлы были проанализированы на предмет NPC, т.к. в этих играх описания взаимодействия с неодушевленными предметами: порталами, сферами и т.д. Из-за того, что такие описания не содержат непосредственно диалогов, они были удалены из выборки. Также было замечено, что в игре Planescape: Torment: Enhanced Edition в отличие от остальных игр на движке Infinity Engine в диалоговых файлах помимо самих диалогов в текстовом виде достаточно часто было описано то, что видит перед собой игрок, что в последствии сильно поможет составлению набора данных. Такую полезную информацию нельзя упускать и следует иметь помимо обычных реплик NPC дополнительный контекст диалога. К тому же игра обладает самым большим корпусом диалогов и в качестве анализируемых данных будут использованы диалоги из Planescape: Torment: Enhanced Edition.

3. СИНТЕЗ ОПИСАНИЙ NPC И АНАЛИЗ НАБОРА ДАННЫХ

3.1. ПОЛУЧЕНИЕ ОПИСАНИЙ NPC

Хотя получение диалогов NPC является необходимым первым шагом в создании набора данных для моделирования диалогов, этого недостаточно, если учесть важность имитации ответов NPC в наборе данных. Анализ доступных инструментов модификации игр для Infinity Engine показал, что преобразование имен файлов диалогов в соответствующие символы, отображаемые в игре, требует логики, специфичной для игры, а получение имен персонажей из имен файлов диалогов с помощью обычных инструментов весьма неоднозначно. Чтобы преодолеть эту проблему, были использованы передовые языковые модели (LLM) для синтеза описаний NPC в определенном формате. Был использован метод Few-Shot, который включал предоставление примеров реплик NPC, содержащих частичные описания NPC. В результате алгоритм получения описаний NPC выглядит следующим образом:

1. Все диалоги группируются по имени файла, из которого были получены диалоги NPC с игроком
2. Формируются уникальные и упорядочные примеры реплик NPC так, чтобы количество токенов в примерах + количество токенов в инструкции не превышало 512 токенов
3. Примеры реплик вместе с инструкцией отправляются в виде запроса на сервер, обслуживающий модель
4. Полученный ответ записывается в файл формата «.csv» в виде filename, description

Все эксперименты были выполнены на потребительском оборудовании, включающем 32 Гб оперативной памяти, 20-ядерный процессор и графический процессор NVIDIA RTX 3090Ti с объемом памяти 24 Гб. Поэтому синтез данных не был проводим на оборудовании максимальной мощности, но доступном для исследований. На начало первого квартала 2023 года, одним из

наиболее эффективных семейств предобученных моделей для генерации текста по количеству параметров и выходных метрик является LLaMa [13]. На основе инструкционных данных, было разработано семейство моделей Alпаса [14], которые достигают качества ответов, сопоставимого с результатами модели ChatGPT [15].

Ограничения потребительского оборудования сказались и на размере контекста, вмещаемого в модель. Экспериментно было определено, что максимальный размер входной последовательности составляет 512 токенов, а максимальный размер выходной – 256. В связи с ограничениями на размер входных данных диалог отправляется не весь, а только лишь его часть и при том реплики NPC, потому как в них содержится описание NPC. Было обнаружено, что реплики игрока не влияют на синтезируемое описание NPC, что позволяет экономить размер входных данных.

Для робастного синтеза данных пробовались различные комбинации инструкций и параметров генерации модели. Иногда ответы LLM не соответствуют требуемому формату, в таком случае стоит пробовать разные подходы к написанию инструкций. Например, использование формулировки «Сгенерируй данные в формате: ПРИМЕР_ФОРМАТА» в отрыве от «Сгенерируй данные в формате: ПРИМЕР_ФОРМАТА, НЕ ИСПОЛЬЗУЯ [ПРИМЕР]», позволяет получить необходимый ответ с меньшим количеством галлюцинаций и ошибок. Такое поведение можно обосновать тем, что корпус текстов с такими видами формулировок использованный в качестве данных для обучения был больше.

Выгода использования LLM для синтеза данных проявляется еще в том, что не для всех NPC написаны описания на таких ресурсах, как wiki и др. Поэтому используя такой подход большее количество данных можно покрыть необходимыми описаниями.

В данной работе в качестве инструкции была выбрана следующая инструкция: «Create the personality of a single NPC in DnD style, based on the provided example dialogue in JSON format. Answer in format Name/Alignment/Description/Flaw/Motivation/Personality in a list format written in third person». Таким образом были получены описания NPC и датасет DNDD имеет все необходимые компоненты для обучения диалоговой модели.

По данной инструкции были сгенерированы подобные описания:
Name: The Drunk

Alignment: Neutral

Description: A disheveled, stench-ridden waste of a life.

Flaw: Drunk out of his gourd.

Motivation: To get more alcohol.

Personality: The drunk is confused and disoriented, but he is also desperate for more alcohol. He is willing to do anything to get it, even if it means stealing from others.

3.2. АНАЛИЗ DNDD

Набор данных состоит из 4,5 гигабайт текстовой информации, содержащей в общей сложности 981 тысячу диалогов и 986 миллионов токенов, среди которых 824 миллиона соответствуют ответам NPC. Это составляет 83% от общего количества токенов. Набор данных также включает 27 миллионов ходов, причем ответы NPC представляют 14 миллионов из них. Примечательно, что некоторые взаимодействия NPC с игроком состоят только из одного предложения. На рисунках 3.1, 3.2 отображены распределения частоты диалоговых ходов по длине, а на рисунках 3.3, 3.4 отображены распределения частоты количества токенов в диалоге по количеству. Наблюдения показывают, что реакция NPC имеет более продолжительную среднюю продолжительность по сравнению с реакцией игрока. Это можно объяснить отличительной особенностью ответов NPC, которая включает в себя хранение дополнительной контекстуальной информации, что приводит к более полному пониманию текущего разговора и, следовательно, к диалогам более высокого качества.




Рисунок 3.1 – Распределение частоты диалоговых ходов NPC по длине




Рисунок 3.2 – Распределение частоты диалоговых ходов игрока по длине




Рисунок 3.3 – Распределение частоты количества токенов в диалоге NPC по количеству




Рисунок 3.4 – Распределение частоты количества токенов в диалоге игрока по количеству

4. ПОДГОТОВКА НАБОРА ДАННЫХ DNDD ДЛЯ ОБУЧЕНИЯ МОДЕЛЕЙ

После фазы сбора диалоговых данных и генерации параметров неигровых персонажей, включающих в себя идентификаторы, характеристики, мировоззрение, мотивацию и слабости, следующим логическим этапом становится подготовка собранных данных к процессу обучения модели. Этот процесс включает в себя конкатенацию данных в строковом формате.

4.1. ЭМУЛЯЦИЯ ДИАЛОГОВЫХ ВЗАИМОДЕЙСТВИЙ

Особое внимание следует уделить диалоговым взаимодействиям между неигровым персонажем и игроком. В контексте набора данных, где хранятся полные версии диалогов, эмуляция процесса общения игрока с неигровым персонажем требует разбиения истории диалога на подмножества. В этом случае диалог представляет собой серию ходов между игроком и неигровым персонажем, и основной задачей модели является продолжение данного диалога, т.е. совершение следующего хода в диалоге.

При таком подходе модель обучается на основе итеративного процесса диалога, что способствует приближению к более реалистичному моделированию процесса диалога. Это позволяет на каждом этапе оптимизировать процесс обучения для достижения максимально эффективного результата.

4.2. СТРУКТУРИРОВАНИЕ ВХОДНЫХ ДАННЫХ ДЛЯ ОБУЧЕНИЯ

Для оптимизации процесса обучения, входные последовательности, а именно описание неигрового персонажа, история диалогов с игроком, последняя реплика игрока и реплика, которую должна сгенерировать модель, были разделены на сегменты, каждый из которых был помечен соответствующим образом. Такой подход к структурированию входных данных для модели позволяет ясно разделять различные компоненты входных данных, что облегчает задачу модели и способствует более эффективному обучению.

Для обозначения начала диалога используется уникальный идентификатор «EMPTY», который функционирует как сигнал о том, что диалог только

что был инициирован. В силу специфики набора данных DNDD, полученного из игр, где неигровые персонажи всегда начинают диалог первыми, было определено, что первая реплика игрока служит активацией диалога, и обозначена она идентификатором «START DIALOGUE». В ходе последующего диалога реплики участников регистрируются в истории диалога с пометками «Player: » и «NPC: », в зависимости от того, кто в данный момент выступает в роли говорящего.

4.3. ОПТИМИЗАЦИЯ ДАННЫХ ПОД ПОТРЕБИТЕЛЬСКОЕ ОБОРУДОВАНИЕ

Учитывая ограниченные вычислительные ресурсы потребительского уровня, включая оперативную память объемом 32 гигабайта и графическую карту NVIDIA GeForce RTX 3090 Ti с 24 гигабайтами памяти, было необходимо ввести определенные ограничения на обрабатываемую историю диалогов. При превышении диалогом лимита в 1024 токенов, для обеспечения управляемости данных самые старые записи в диалоге подлежали удалению. Это позволяло оптимизировать использование доступных вычислительных ресурсов и обеспечивать стабильный процесс обучения моделей.

Также было ограничено максимальное количество диалогов, которых может иметь игрок с одним неигровым персонажем. Это позволяет иметь меньшее, но более разнообразное количество данных.

Итоговые данные выглядят следующим образом. Входная последовательность:

Below is the definition of in-game NPC.

NPC Name: Digby

Alignment: Neutral

Description: A burly, bearded man with a thick accent and a penchant for trapping.

Personality traits: Digby is a bit of a glutton, and often overindulges in food and drink.

Flaws: Digby is motivated by the prospect of making a profit from his trapping.

Motivation: Digby is a gruff, no-nonsense man who is quick to anger and slow to trust. He is a hard worker

and is not afraid to get his hands dirty. He is also a bit of a glutton, and often overindulges in food and drink.

Dialogue history:

Player: START DIALOGUE

NPC: *burp* Think I had too much to drink last night. Heh! What am I sayin'?! There's no such thing, says my brothers. Hey, who are you, anyway?

Player query: Who are you?

Respond to player's query based on defined NPC:

Ожидаемый ответ: I'm Digby. I'm a trapper 'round these parts. Me and my brothers catch all sorts of varmints, skin 'em, and sell 'em. Course, it's hard lately now that Emmerich is pokin' 'round.

Детальная реализация обработки набора данных с документацией доступна в приложении Б.

5. ОБУЧЕНИЕ МОДЕЛИ

5.1. ПОИСК ОПТИМАЛЬНОЙ МОДЕЛИ

Генеративные модели обычно имеют большой размер, что создает сложности при исследовании таких моделей. Поэтому важным фактором при выборе модели является соотношение размера и качества. В настоящее время одним из самых сложных датасетов является MMLU [16], который проверяет знания моделей, полученных во время предварительного обучения, на различных задачах. Этот датасет включает задачи с разной степенью сложности, от простых до профессиональных. На данный момент наиболее оптимальной моделью на этом бенчмарке является Flan-T5-XL [12] с 3 миллиардами параметров, имея результат 52.4%. Еще одной моделью, которая может составить ей конкуренцию, является LLAMA-13B [13] с результатом 46.9%, но ее большой размер делает процесс обучения значительно более затратным по сравнению с Flan-T5-XL.

Flan-T5 является моделью семейства T5 [11], добавляющая в дообучающую выборку большое количество инструкций, что позволило значительно улучшить качество модели на новых задачах.

5.2. ПОИСК ОПТИМАЛЬНЫХ ГИПЕРПАРАМЕТРОВ ДЛЯ МОДЕЛИ

5.2.1. ПОСТАНОВКА ЗАДАЧИ

Из гиперпараметров, значительно влияющих на процесс обучения модели, было выделено три группы:

1. Планировщики скорости обучения:

- константный;
- константный с прогревом;
- линейный;
- косинусный;
- косинусный с перезагрузками;
- полиномиальный;

- обратный квадратный корень.

2. Скорость обучения $\in \{1 \times 10^{-4}, 2 \times 10^{-4}, \dots, 9 \times 10^{-4}, 1 \times 10^{-3}\}$.

Оценка качества генерации моделей является сложной задачей и малоисследованной. В данной работе помимо значений функции ошибки на валидационных данных используются метрики Exact Match и MAUVE, позволяющие сравнивать параметры между собой. Модель обучалась с различными гиперпараметрами в группе, пока остальные параметры фиксировались.

Метрика Exact Match показывает, какой процент фраз при генерации совпал с ожидаемыми, а MAUVE подсчитывает то, насколько совпало распределение вероятностей сгенерированных фраз с распределением вероятностей ожидаемых фраз.

5.2.2. АНАЛИЗ РЕЗУЛЬТАТОВ ЭКСПЕРИМЕНТОВ С ГИПЕРПАРАМЕТРАМИ

При стартовой скорости обучения равной 1×10^{-3} на ограниченном наборе данных были произведены эксперименты по поиску оптимального планировщика скорости обучения. В процессе экспериментов отмечается, что планировщик с обратным квадратным корнем не представлен на графиках, так как ни один из запусков эксперимента с использованием этого планировщика не был успешно завершен.

В ходе экспериментов большинство планировщиков не оказало заметного влияния на скорость обучения и метрики. Среди рассмотренных вариантов планировщиков, в среднем наилучшие результаты продемонстрировал константный планировщик. Наименее эффективным, но успешно завершившим процесс обучения, оказался линейный планировщик. Отмечается, что линейный планировщик характеризуется низким начальным значением функции ошибки на тренировочных и показывает наихудшие конечные значения на метрике MAUVE, что иллюстрируется на рисунках 5.1 и 5.4. График изменения скорости обучения представлен на рисунке 5.5. Ход экспериментов можно наблюдать на рисунках 5.1, 5.2, 5.3, 5.4




Рисунок 5.1 – Значение функции ошибки на тренировочных данных




Рисунок 5.2 – Значение функции ошибки на валидационных данных




Рисунок 5.3 – Значение метрики Exact Match на валидационных данных




Рисунок 5.4 – Значение метрики MAUVE на валидационных данных



Рисунок 5.5 – График изменения скорости обучения

В следующих экспериментах при зафиксированном константном планировщике скорости обучения искалась наиболее эффективная скорость обучения. Стоит отметить, что при скорости обучения равной 1×10^{-4} процесс обучения не завершился успешно. Из рисунков 5.6, 5.7, 5.8, 5.9 видно, что значения, близкие к 4×10^{-4} и к 9×10^{-4} показывают лучшие значения функций ошибок на всех выборках и лучшие значения метрик. Значение скорости обучения 9×10^{-4} показывает результаты чуть лучше, чем 4×10^{-4} , быстрее достигая лучших значений. В целом, почти все значения скорости обучения показывают схожие результаты, но выбор оптимальных параметров для обучения на большей выборке может сказаться на качестве модели.




Рисунок 5.6 – Значение функции ошибки на тренировочных данных



Рисунок 5.7 – Значение функции ошибки на валидационных данных




Рисунок 5.8 – Значение метрики Exact Match на валидационных данных




Рисунок 5.9 – Значение метрики MAUVE на валидационных данных

Исходя из всех экспериментов можно сделать вывод, что оптимальные параметры для обучения будут константный планировщик скорости обучения и скорость обучения со значением 9×10^{-4}

5.3. ОБУЧЕНИЕ ИТОГОВОЙ МОДЕЛИ

С подобранными ранее параметрами на была обучена итоговая модель. Общее количество операций, произведенных во время обучения, составило 2×10^{18} . Количество токенов, которые фигурировали в процессе обучения – 25×10^6 . Процесс обучения виден на рисунках 5.10, 5.11, 5.12, 5.13. Низкие значения метрик Exact Match и MAUVE можно объяснить сложностью поставленной модели задачи: в диалогах часто ответы формируются исходя из внешних условий, в которых происходил диалог с неигровым персонажем, которые сложно получить из данных игры в формате естественного языка. Метрика Exact Match довольно грубо оценивает результат генерации – переформулированная фраза в такой оценке даст значение 0. Тем не менее, такую систему получилось обучить на потребительском оборудовании на неплохие результаты. Далее идет пример диалога, который был произведен с моделью.

Below is the definition of in-game NPC.

The Mad Lord

Alignment: Chaotic Neutral

Description: A mysterious figure who resides in a castle called Caste Maluradek in the middle of a forest. He is a powerful wizard who has the ability to manipulate the elements and create illusions.

Personality traits: He is obsessed with power and will stop at nothing to achieve his goals.

Flaws: He wants to prove that he is the most powerful wizard in the world.

Motivation: The Mad Lord is a mysterious figure who is driven by his desire for power. He is a master manipulator and will use any means necessary to achieve his goals. He is a powerful wizard who is not afraid to use his magic to get what he wants. He is also a bit of a showman, as he enjoys creating elaborate illusions to impress his guests.

Dialogue history:

Player: START DIALOGUE

NPC: Salutations to the travelers. Welcome to Castle Maluradek. I am your adversary.

Player query: Does the adversary have a name?

Respond to player's query based on defined NPC:

ANSWER: I do not have a name. I am a practitioner of magic. I work in the fields of the great forest.

Больше примеров можно увидеть в приложении В.



Рисунок 5.10 – Значение функции ошибки на тренировочных данных



Рисунок 5.11 – Значение функции ошибки на валидационных данных




Рисунок 5.12 – Значение метрики Exact Match на валидационных данных




Рисунок 5.13 – Значение метрики MAUVE на валидационных данных

ЗАКЛЮЧЕНИЕ

В рамках данного исследования была поставлена цель разработки эффективной диалоговой модели, способной генерировать качественные ответы на основе образа неигрового персонажа и контекста диалога в игровой индустрии. Был использован специально созданный для исследования датасет DNDD (Dungeon & Dragons Dialogues). И подготовлен специально для эмулирования диалогов в играх. В процессе экспериментов были рассмотрены различные параметры и планировщики скорости обучения.

На основе проведенных экспериментов можно сделать вывод о наилучшем выборе параметров для обучения модели. Для модели Flan-T5 был выявлен оптимальный планировщик скорости обучения - константный планировщик, а оптимальное значение скорости обучения составляет 9×10^{-4} . Это сочетание показало лучшие результаты по функциям ошибок и метрикам на представленных наборах данных.

Однако, следует отметить, что введенная сложность задачи диалоговой моделирования в игровой индустрии, где ответы зависят от различных условий и контекста диалога, может быть причиной низких значений метрик Exact Match и MAUVE. Оценка Exact Match грубо оценивает результат генерации, причем даже переформулировка фразы может привести к низким значениям.

В целом, полученные результаты демонстрируют возможность обучения эффективной диалоговой модели на доступных вычислительных ресурсах. Однако, дальнейшие исследования и улучшения в области диалоговых моделей могут привести к более точным и качественным результатам.

СПИСОК ЛИТЕРАТУРЫ

1. Lippmann R. P. Speech recognition by machines and humans [Текст] // Speech communication. – 1997. – Т. 22. – №. 1. – С. 1-15.
2. Radford A. et al. Robust speech recognition via large-scale weak supervision [Текст] // arXiv preprint arXiv:2212.04356. – 2022.
3. Karpathy A. State of GPT [Электронный ресурс]. — URL: <https://karpathy.ai/stateofgpt.pdf> (дата обр. 11.06.2023)
4. Vaswani A. et al. Attention is all you need [Текст] // Advances in neural information processing systems. – 2017. – Т. 30.
5. Hecht-Nielsen R. Theory of the backpropagation neural network [Текст] // Neural networks for perception. – Academic Press, 1992. – С. 65-93.
6. Ruder S. An overview of gradient descent optimization algorithms [Текст] // arXiv preprint arXiv:1609.04747. – 2016.
7. Shazeer N., Stern M. Adafactor: Adaptive learning rates with sublinear memory cost [Текст] // International Conference on Machine Learning. – PMLR, 2018. – С. 4596-4604.
8. Mikolov T. et al. Efficient estimation of word representations in vector space [Текст] // arXiv preprint arXiv:1301.3781. – 2013.
9. Sennrich R., Haddow B., Birch A. Neural machine translation of rare words with subword units [Текст] // arXiv preprint arXiv:1508.07909. – 2015.
10. Kudo T., Richardson J. Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing [Текст] // arXiv preprint arXiv:1808.06226. – 2018.
11. Raffel C. et al. Exploring the limits of transfer learning with a unified text-to-text transformer [Текст] // The Journal of Machine Learning Research. – 2020. – Т. 21. – №. 1. – С. 5485-5551.

12. Chung H. W. et al. Scaling instruction-finetuned language models [Текст] // arXiv preprint arXiv:2210.11416. – 2022.
13. Touvron H. et al. Llama: Open and efficient foundation language models [Текст] // arXiv preprint arXiv:2302.13971. – 2023.
14. Документация Alpaca [Электронный ресурс]. — URL: <https://crfm.stanford.edu/2023/03/13/alpaca.html> (дата обр. 06.06.2023)
15. Документация ChatGPT [Электронный ресурс]. — URL: <https://openai.com/blog/chatgpt> (дата обр. 06.06.2023)
16. Бенчмарк MMLU [Электронный ресурс]. — URL: <https://paperswithcode.com/sota/multi-task-language-understanding-on-mmlu> (дата обр. 06.06.2023)

ПРИЛОЖЕНИЕ А. ПРИМЕР ТРАНСЛЯЦИИ ИЗ ЯЗЫКА D В JSON

```
1 // creator   : WeiDU-Windows/weidu.exe (version 24900)
2 // argument  : ABISHAB.DLG
3 // game      : D:\other\PTEEPAL\App\GameData
4 // source     : D:\other\PTEEPAL\App\GameData\DATA\DLGFILES.BIF
5 // dialog     : D:\other\PTEEPAL\App\GameData\lang\en_us\dialog.tlk
6 // dialogF    : (none)
7
8 BEGIN ~ABISHAB~
9
10 IF ~ Global("Know_Abishai","GLOBAL",0)
11 ~ THEN BEGIN 0 // from:
12     SAY ~This black-scaled reptile towers to a height of eight feet - its great
        height, however, is offset by its thin, snake-like frame. A long
        prehensile tail drags behind it, and its leathery wings are hooked behind
        its back. A strong vinegary smell emanates from the creature... as well as
        a certain amount of heat. It seems to be ignoring you.~ /* #3325 */
13     IF ~ NearbyDialog("DMorte")
14     Global("Morte_Abishai_Hive_Quip_1","GLOBAL",0)
15     ~ THEN REPLY ~"Greetings."~ /* #3326 */ DO
        ~SetGlobal("Morte_Abishai_Hive_Quip_1","GLOBAL",1)
16 ~ EXTERN ~DMORTE~ 131
17     IF ~ NearbyDialog("DMorte")
18     Global("Morte_Abishai_Hive_Quip_1","GLOBAL",1)
19     ~ THEN REPLY ~"Greetings."~ /* #3992 */ EXTERN ~DMORTE~ 133
20     IF ~ !NearbyDialog("DMorte")
21     NearbyDialog("DAnnah")
22     Global("Annah_Abishai_Hive_Quip_1","GLOBAL",0)
23     ~ THEN REPLY ~"Greetings."~ /* #3993 */ DO
        ~SetGlobal("Annah_Abishai_Hive_Quip_1","GLOBAL",1)
24 ~ EXTERN ~DANNAH~ 70
25     IF ~ !NearbyDialog("DMorte")
26     NearbyDialog("DAnnah")
27     Global("Annah_Abishai_Hive_Quip_1","GLOBAL",1)
28     ~ THEN REPLY ~"Greetings."~ /* #3994 */ EXTERN ~DANNAH~ 72
29     IF ~ !NearbyDialog("DMorte")
30     !NearbyDialog("DAnnah")
31     ~ THEN REPLY ~"Greetings."~ /* #3995 */ GOTO 1
32     IF ~~ THEN REPLY ~Leave the creature alone.~ /* #7718 */ EXIT
33 END
34
35 IF ~~ THEN BEGIN 1 // from: 11.0 0.4
```

```

36     SAY ~The creature slowly turns its head down to look at you. Its scaled
        forehead wrinkles into a frown, then it opens its mouth, giving a low,
        rasping hiss. You notice that the heat radiating from the creature begins
        to rise.~ /* #7719 */
37     IF ~ !NearbyDialog("DAnnah")
38     !NearbyDialog("DGrace")
39     ~ THEN REPLY ~"I_would_speak_with_you_for_a_moment."~ /* #7720 */ GOTO 2
40     IF ~ NearbyDialog("DAnnah")
41     !NearbyDialog("DGrace")
42     ~ THEN REPLY ~"I_would_speak_with_you_for_a_moment."~ /* #7721 */ GOTO 6
43     IF ~ NearbyDialog("DGrace")
44     ~ THEN REPLY ~"I_would_speak_with_you_for_a_moment."~ /* #7722 */ GOTO 6
45     IF ~~ THEN REPLY ~Leave the creature alone.~ /* #7723 */ EXIT
46 END
47
48 IF ~~ THEN BEGIN 2 // from: 1.0
49     SAY ~The creature opens its mouth, displaying a row of blackened fangs. Fire
        begins to dance around the shoulders and arms of the creature as it gives
        a long, low hiss.~ /* #7724 */
50     IF ~~ THEN REPLY ~"Calm_yourself!_I_just_want_to_talk_to_you."~ /* #7725 */
        GOTO 4
51     IF ~~ THEN REPLY ~Hiss back.~ /* #7726 */ GOTO 3
52     IF ~~ THEN REPLY ~Leave the creature alone.~ /* #7727 */ EXIT
53 END
54
55 IF ~~ THEN BEGIN 3 // from: 5.1 5.0 2.1
56     SAY ~The creature roars, then it launches itself at you!~ /* #7728 */
57     IF ~~ THEN REPLY ~Defend yourself...~ /* #7730 */ DO ~Enemy()
58     Attack(Protagonist)
59     ForceAttack(Protagonist,Myself)
60     ~ EXIT
61 END
62
63 IF ~~ THEN BEGIN 4 // from: 2.0
64     SAY ~The creature speaks in a rasping hiss; its voice sounds like two rough
        stones being scraped together. It hisses for a few moments, its gravelly
        voice rising and falling.~ /* #7731 */
65     IF ~~ THEN REPLY ~"Uh..._what?"~ /* #7732 */ GOTO 5
66     IF ~~ THEN REPLY ~Leave the creature alone.~ /* #7733 */ EXIT
67 END
68
69 IF ~~ THEN BEGIN 5 // from: 4.0
70     SAY ~The creature snarls. "NOTHING_to_sssay_to_you,_do_I." The fiend's_eyes_
        narrow_to_slits._"If_ssstay,_your_warm_blood_will_cover_the_ssstones."_~/*_
        #7734_*/
71     IF ~~ THEN REPLY ~"I_just_wanted_to_ask_you_some_questions..."~/*_#7735_*/_
        GOTO_3

```

```

72  IF~~THENREPLY~"Justtryit,andwe'll see whose blood covers the street
    when we're done."~/*#7736*/GOTO3
73  IF~~THENREPLY~Backoffandleave the creature alone.~/*#7737*/EXIT
74  END
75
76  IF~~THENBEGIN6//from:1.21.1
77  SAY~The creature suddenly sniffs the air, then turns away from you with a
    strange hiss. It seems to have caught some unpleasant scent.~/*#7738*/
78  IF~NearbyDialog("DGrace")
79  ~THENREPLY~"I said, I would speak with you."~/*#7739*/GOTO8
80  IF~NearbyDialog("DAnnah")
81  !NearbyDialog("DGrace")
82  ~THENREPLY~"I said, I would speak with you."~/*#7740*/GOTO7
83  IF~~THENREPLY~Leave the creature alone.~/*#7741*/EXIT
84  END
85
86  IF~~THENBEGIN7//from:6.1
87  SAY~The creature's eyes focus on Annah, then narrow to slits. It opens its
    mouth, displaying a row of blackened fangs as fire begins to dance around
    the shoulders and arms of the creature. The heat emanating from it begins to
    rise.~ /* #7742 */
88  IF ~~ THEN REPLY ~"Hey! I'm talking to you!"~ /* #7743 */ GOTO 9
89  IF ~~ THEN REPLY ~Leave the creature alone, take Annah and leave.~ /* #7744
    */ EXIT
90  END
91
92  IF ~~ THEN BEGIN 8 // from: 6.0
93  SAY ~The creature's eyes focus on Fall-from-Grace, then narrow to slits. It
    opens its mouth, displaying a row of blackened fangs as fire begins to
    dance around the shoulders and arms of the creature. The heat emanating
    from it begins to rise.~/*#7745*/
94  IF~~THENREPLY~"Hey! I'm talking to you!"~/*#7746*/GOTO10
95  IF~~THENREPLY~Back away, taking Fall-from-Grace with you and leave.~/*
    #7747*/EXIT
96  END
97
98  IF~~THENBEGIN9//from:7.0
99  SAY~The creature roars, then it launches itself at Annah!~/*#7748*/
100 IF~~THENREPLY~"Dammit..."~/*#7749*/DO~Enemy()
101 Attack("Annah")
102 ~EXIT
103 END
104
105 IF~~THENBEGIN10//from:8.0
106 SAY~The creature roars, then it launches itself at Fall-from-Grace!~/*
    #7750*/
107 IF~~THENREPLY~"Dammit..."~/*#7751*/DO~Enemy()
108 Attack("Grace")

```

```

109 ~_EXIT
110 END
111
112 IF~_Global("Know_Abishai","GLOBAL",1)
113 ~_THEN_BEGIN_11_//_from:
114 _SAY~This_black-scaled_fiend_towers_to_a_height_of_eight_feet_its_great_
    height,_however,_is_offset_by_its_thin,_snake-like_frame._A_long_prehensile_
    tail_drags_behind_it,_and_its_leathery_wings_are_hooked_behind_its_back._A_
    strong_vinegary_smell_emanates_from_the_fiend...as_well_as_a_certain_amount_
    of_heat._It_seems_to_be_ignoring_you._~/*_#7752_*/
115 _IF~_~_THEN_REPLY~"Greetings._~/*_#7753_*/_GOTO_1
116 _IF~_~_THEN_REPLY~Leave_the_abishai_alone._~/*_#7758_*/_EXIT
117 END

```

Листинг А.1: Файл abishab.d

```

1  [
2      {
3          "Id": 0,
4          "HeroSpeech": [
5              "\"Greetings.\",
6              "\"I_would_speak_with_you_for_a_moment.\",
7              "\"I_said,_I_would_speak_with_you.\",
8              "\"Hey!_I'_m_talking_to_you!\",
9          ],
10         "CharacterSpeech": [
11             "This_black-scaled_reptile_towers_to_a_height_of_eight_feet_its_
                great_height,_however,_is_offset_by_its_thin,_snake-like_frame._
                A_long_prehensile_tail_drags_behind_it,_and_its_leathery_wings_
                are_hooked_behind_its_back._A_strong_vinegary_smell_emanates_
                from_the_creature...as_well_as_a_certain_amount_of_heat._It_
                seems_to_be_ignoring_you.",
12             "The_creature_slowly_turns_its_head_down_to_look_at_you._Its_scaled_
                forehead_wrinkles_into_a_frown,_then_it_opens_its_mouth,_giving_
                a_low,_rasping_hiss._You_notice_that_the_heat_radiating_from_the_
                creature_begins_to_rise.",
13             "The_creature_suddenly_sniffs_the_air,_then_turns_away_from_you_
                with_a_strange_hiss._It_seems_to_have_caught_some_unpleasant_
                scent.",
14             "The_creature's_eyes_focus_on_Annah,_then_narrow_to_slits._It_opens_
                its_mouth,_displaying_a_row_of_blackened_fangs_as_fire_begins_to_
                dance_around_the_shoulders_and_arms_of_the_creature._The_heat_
                emanating_from_it_begins_to_rise.",
15             "The_creature_roars,_then_it_launches_itself_at_Annah!"
16         ]
17     },
18     {
19         "Id": 1,

```

```

20     "HeroSpeech": [
21         "\"Greetings.\"\"",
22         "\"I would speak with you for a moment.\"\"",
23         "\"I said, I would speak with you.\"\"",
24         "\"Hey! I'm talking to you!\""
25     ],
26     "CharacterSpeech": [
27         "This black-scaled reptile towers to a height of eight feet-its
           great height, however, is offset by its thin, snake-like frame.
           A long prehensile tail drags behind it, and its leathery wings
           are hooked behind its back. A strong vinegary smell emanates
           from the creature...as well as a certain amount of heat. It
           seems to be ignoring you.",
28         "The creature slowly turns its head down to look at you. Its scaled
           forehead wrinkles into a frown, then it opens its mouth, giving
           a low, rasping hiss. You notice that the heat radiating from the
           creature begins to rise.",
29         "The creature suddenly sniffs the air, then turns away from you
           with a strange hiss. It seems to have caught some unpleasant
           scent.",
30         "The creature's eyes focus on Fall-from-Grace, then narrow to
           slits. It opens its mouth, displaying a row of blackened fangs
           as fire begins to dance around the shoulders and arms of the
           creature. The heat emanating from it begins to rise.",
31         "The creature roars, then it launches itself at Fall-from-Grace!"
32     ]
33 },
34 {
35     "Id": 2,
36     "HeroSpeech": [
37         "\"Greetings.\"\"",
38         "\"I would speak with you for a moment.\"\"",
39         "\"I said, I would speak with you.\"\"",
40         "\"Hey! I'm talking to you!\""
41     ],
42     "CharacterSpeech": [
43         "This black-scaled reptile towers to a height of eight feet-its
           great height, however, is offset by its thin, snake-like frame.
           A long prehensile tail drags behind it, and its leathery wings
           are hooked behind its back. A strong vinegary smell emanates
           from the creature...as well as a certain amount of heat. It
           seems to be ignoring you.",
44         "The creature slowly turns its head down to look at you. Its scaled
           forehead wrinkles into a frown, then it opens its mouth, giving
           a low, rasping hiss. You notice that the heat radiating from the
           creature begins to rise.",

```

```

45         "The creature suddenly sniffs the air, then turns away from you
           with a strange hiss. It seems to have caught some unpleasant
           scent.",
46         "The creature's eyes focus on Annah, then narrow to slits. It opens
           its mouth, displaying a row of blackened fangs as fire begins to
           dance around the shoulders and arms of the creature. The heat
           emanating from it begins to rise.",
47         "The creature roars, then it launches itself at Annah!"
48     ]
49 },
50 {
51     "Id": 3,
52     "HeroSpeech": [
53         "\"Greetings.\",",
54         "\"I would speak with you for a moment.\",",
55         "\"I said, I would speak with you.\",",
56         "\"Hey! I'm talking to you!\",",
57     ],
58     "CharacterSpeech": [
59         "This black-scaled reptile towers to a height of eight feet - its
           great height, however, is offset by its thin, snake-like frame. A
           long prehensile tail drags behind it, and its leathery wings
           are hooked behind its back. A strong vinegary smell emanates
           from the creature... as well as a certain amount of heat. It
           seems to be ignoring you.",
60         "The creature slowly turns its head down to look at you. Its scaled
           forehead wrinkles into a frown, then it opens its mouth, giving
           a low, rasping hiss. You notice that the heat radiating from the
           creature begins to rise.",
61         "The creature suddenly sniffs the air, then turns away from you
           with a strange hiss. It seems to have caught some unpleasant
           scent.",
62         "The creature's eyes focus on Fall-from-Grace, then narrow to
           slits. It opens its mouth, displaying a row of blackened fangs
           as fire begins to dance around the shoulders and arms of the
           creature. The heat emanating from it begins to rise.",
63         "The creature roars, then it launches itself at Fall-from-Grace!"
64     ]
65 },
66 {
67     "Id": 4,
68     "HeroSpeech": [
69         "\"Greetings.\",",
70         "\"I would speak with you for a moment.\",",
71         "Hiss back."
72     ],
73     "CharacterSpeech": [

```

```

74         "This black-scaled reptile towers to a height of eight feet - its
           great height, however, is offset by its thin, snake-like frame. A
           long prehensile tail drags behind it, and its leathery wings
           are hooked behind its back. A strong vinegary smell emanates
           from the creature... as well as a certain amount of heat. It
           seems to be ignoring you.",
75         "The creature slowly turns its head down to look at you. Its scaled
           forehead wrinkles into a frown, then it opens its mouth, giving
           a low, rasping hiss. You notice that the heat radiating from the
           creature begins to rise.",
76         "The creature opens its mouth, displaying a row of blackened fangs.
           Fire begins to dance around the shoulders and arms of the
           creature as it gives a long, low hiss.",
77         "The creature roars, then it launches itself at you!"
78     ],
79 },
80 {
81     "Id": 5,
82     "HeroSpeech": [
83         "\"Greetings.\"\"",
84         "\"I would speak with you for a moment.\"\"",
85         "\"Calm yourself! I just want to talk to you.\"\"",
86         "\"Uh... what?\"",
87         "\"Just try it, and we'll see whose blood covers the street when
           we're done.\"\"",
88     ],
89     "CharacterSpeech": [
90         "This black-scaled reptile towers to a height of eight feet - its
           great height, however, is offset by its thin, snake-like frame. A
           long prehensile tail drags behind it, and its leathery wings
           are hooked behind its back. A strong vinegary smell emanates
           from the creature... as well as a certain amount of heat. It
           seems to be ignoring you.",
91         "The creature slowly turns its head down to look at you. Its scaled
           forehead wrinkles into a frown, then it opens its mouth, giving
           a low, rasping hiss. You notice that the heat radiating from the
           creature begins to rise.",
92         "The creature opens its mouth, displaying a row of blackened fangs.
           Fire begins to dance around the shoulders and arms of the
           creature as it gives a long, low hiss.",
93         "The creature speaks in a rasping hiss; its voice sounds like two
           rough stones being scraped together. It hisses for a few
           moments, its gravelly voice rising and falling.",
94         "The creature snarls. \"NOTHING to sssay to you, do I.\" The
           fiend's eyes narrow to slits. \"If sssstay, your warm blood will
           cover the sssstones.\"\"",
95         "The creature roars, then it launches itself at you!"
96     ]

```



```

97     },
98     {
99         "Id": 6,
100         "HeroSpeech": [
101             "\"Greetings.\"\"",
102             "\"I would speak with you for a moment.\"\"",
103             "\"Calm yourself! I just want to talk to you.\"\"",
104             "\"Uh... what?\"",
105             "\"I just wanted to ask you some questions...\""
106         ],
107         "CharacterSpeech": [
108             "This black-scaled reptile towers to a height of eight feet - its great height, however, is offset by its thin, snake-like frame. A long prehensile tail drags behind it, and its leathery wings are hooked behind its back. A strong vinegary smell emanates from the creature... as well as a certain amount of heat. It seems to be ignoring you.",
109             "The creature slowly turns its head down to look at you. Its scaled forehead wrinkles into a frown, then it opens its mouth, giving a low, rasping hiss. You notice that the heat radiating from the creature begins to rise.",
110             "The creature opens its mouth, displaying a row of blackened fangs. Fire begins to dance around the shoulders and arms of the creature as it gives a long, low hiss.",
111             "The creature speaks in a rasping hiss; its voice sounds like two rough stones being scraped together. It hisses for a few moments, its gravelly voice rising and falling.",
112             "The creature snarls. \"NOTHING to sssay to you, do I.\" The fiend's eyes narrow to slits. \"If sssstay, your warm blood will cover the sssstones.\"\"",
113             "The creature roars, then it launches itself at you!"
114         ]
115     },
116     {
117         "Id": 7,
118         "HeroSpeech": [
119             "\"Greetings.\"\"",
120             "\"I would speak with you for a moment.\"\"",
121             "\"I said, I would speak with you.\"\"",
122             "\"Hey! I'm talking to you!\""
123         ],
124         "CharacterSpeech": [
125             "This black-scaled fiend towers to a height of eight feet - its great height, however, is offset by its thin, snake-like frame. A long prehensile tail drags behind it, and its leathery wings are hooked behind its back. A strong vinegary smell emanates from the fiend... as well as a certain amount of heat. It seems to be ignoring you.",

```

```

126         "The creature slowly turns its head down to look at you. Its scaled
            forehead wrinkles into a frown, then it opens its mouth, giving
            a low, rasping hiss. You notice that the heat radiating from the
            creature begins to rise.",
127         "The creature suddenly sniffs the air, then turns away from you
            with a strange hiss. It seems to have caught some unpleasant
            scent.",
128         "The creature's eyes focus on Annah, then narrow to slits. It opens
            its mouth, displaying a row of blackened fangs as fire begins to
            dance around the shoulders and arms of the creature. The heat
            emanating from it begins to rise.",
129         "The creature roars, then it launches itself at Annah!"
130     ]
131 },
132 {
133     "Id": 8,
134     "HeroSpeech": [
135         "\"Greetings.\",",
136         "\"I would speak with you for a moment.\",",
137         "\"I said, I would speak with you.\",",
138         "\"Hey! I'm talking to you!\",",
139     ],
140     "CharacterSpeech": [
141         "This black-scaled fiend towers to a height of eight feet - its
            great height, however, is offset by its thin, snake-like frame. A
            long prehensile tail drags behind it, and its leathery wings
            are hooked behind its back. A strong vinegary smell emanates
            from the fiend... as well as a certain amount of heat. It seems
            to be ignoring you.",
142         "The creature slowly turns its head down to look at you. Its scaled
            forehead wrinkles into a frown, then it opens its mouth, giving
            a low, rasping hiss. You notice that the heat radiating from the
            creature begins to rise.",
143         "The creature suddenly sniffs the air, then turns away from you
            with a strange hiss. It seems to have caught some unpleasant
            scent.",
144         "The creature's eyes focus on Fall-from-Grace, then narrow to
            slits. It opens its mouth, displaying a row of blackened fangs
            as fire begins to dance around the shoulders and arms of the
            creature. The heat emanating from it begins to rise.",
145         "The creature roars, then it launches itself at Fall-from-Grace!"
146     ]
147 },
148 {
149     "Id": 9,
150     "HeroSpeech": [
151         "\"Greetings.\",",
152         "\"I would speak with you for a moment.\",",

```

```

153         "\I said, I would speak with you.\\"",
154         "\"Hey! I'm talking to you!\""
155     ],
156     "CharacterSpeech": [
157         "This black-scaled fiend towers to a height of eight feet - its
            great height, however, is offset by its thin, snake-like frame. A
            long prehensile tail drags behind it, and its leathery wings
            are hooked behind its back. A strong vinegary smell emanates
            from the fiend... as well as a certain amount of heat. It seems
            to be ignoring you.",
158         "The creature slowly turns its head down to look at you. Its scaled
            forehead wrinkles into a frown, then it opens its mouth, giving
            a low, rasping hiss. You notice that the heat radiating from the
            creature begins to rise.",
159         "The creature suddenly sniffs the air, then turns away from you
            with a strange hiss. It seems to have caught some unpleasant
            scent.",
160         "The creature's eyes focus on Annah, then narrow to slits. It opens
            its mouth, displaying a row of blackened fangs as fire begins to
            dance around the shoulders and arms of the creature. The heat
            emanating from it begins to rise.",
161         "The creature roars, then it launches itself at Annah!"
162     ]
163 },
164 {
165     "Id": 10,
166     "HeroSpeech": [
167         "\"Greetings.\\"",
168         "\"I would speak with you for a moment.\\"",
169         "\"I said, I would speak with you.\\"",
170         "\"Hey! I'm talking to you!\""
171     ],
172     "CharacterSpeech": [
173         "This black-scaled fiend towers to a height of eight feet - its
            great height, however, is offset by its thin, snake-like frame. A
            long prehensile tail drags behind it, and its leathery wings
            are hooked behind its back. A strong vinegary smell emanates
            from the fiend... as well as a certain amount of heat. It seems
            to be ignoring you.",
174         "The creature slowly turns its head down to look at you. Its scaled
            forehead wrinkles into a frown, then it opens its mouth, giving
            a low, rasping hiss. You notice that the heat radiating from the
            creature begins to rise.",
175         "The creature suddenly sniffs the air, then turns away from you
            with a strange hiss. It seems to have caught some unpleasant
            scent.",
176         "The creature's eyes focus on Fall-from-Grace, then narrow to
            slits. It opens its mouth, displaying a row of blackened fangs

```

```

        as_fire_begins_to_dance_around_the_shoulders_and_arms_of_the_
        creature._The_heat_emanating_from_it_begins_to_rise.",
177     "The_creature_roars,_then_it_launches_itself_at_Fall-from-Grace!"
178 ]
179 },
180 {
181     "Id": 11,
182     "HeroSpeech": [
183         "\"Greetings.\\"",
184         "\"I_would_speak_with_you_for_a_moment.\\"",
185         "Hiss_back."
186     ],
187     "CharacterSpeech": [
188         "This_black-scaled_fiend_towers_to_a_height_of_eight_feet_-_its_
            great_height,_however,_is_offset_by_its_thin,_snake-like_frame._
            A_long_prehensile_tail_drags_behind_it,_and_its_leathery_wings_
            are_hooked_behind_its_back._A_strong_vinegary_smell_emanates_
            from_the_fiend...as_well_as_a_certain_amount_of_heat._It_seems_
            to_be_ignoring_you.",
189         "The_creature_slowly_turns_its_head_down_to_look_at_you._Its_scaled_
            forehead_wrinkles_into_a_frown,_then_it_opens_its_mouth,_giving_
            a_low,_rasping_hiss._You_notice_that_the_heat_radiating_from_the_
            creature_begins_to_rise.",
190         "The_creature_opens_its_mouth,_displaying_a_row_of_blackened_fangs._
            Fire_begins_to_dance_around_the_shoulders_and_arms_of_the_
            creature_as_it_gives_a_long,_low_hiss.",
191         "The_creature_roars,_then_it_launches_itself_at_you!"
192     ]
193 },
194 {
195     "Id": 12,
196     "HeroSpeech": [
197         "\"Greetings.\\"",
198         "\"I_would_speak_with_you_for_a_moment.\\"",
199         "\"Calm_yourself!_I_just_want_to_talk_to_you.\\"",
200         "\"Uh...what?\"",
201         "\"Just_try_it,_and_we'll_see_whose_blood_covers_the_street_when_
            we're_done.\""
202     ],
203     "CharacterSpeech": [
204         "This_black-scaled_fiend_towers_to_a_height_of_eight_feet_-_its_
            great_height,_however,_is_offset_by_its_thin,_snake-like_frame._
            A_long_prehensile_tail_drags_behind_it,_and_its_leathery_wings_
            are_hooked_behind_its_back._A_strong_vinegary_smell_emanates_
            from_the_fiend...as_well_as_a_certain_amount_of_heat._It_seems_
            to_be_ignoring_you.",
205         "The_creature_slowly_turns_its_head_down_to_look_at_you._Its_scaled_
            forehead_wrinkles_into_a_frown,_then_it_opens_its_mouth,_giving_

```

```

        a_low, rasping hiss. You notice that the heat radiating from the
        creature begins to rise.",
206     "The creature opens its mouth, displaying a row of blackened fangs.
        Fire begins to dance around the shoulders and arms of the
        creature as it gives a long, low hiss.",
207     "The creature speaks in a rasping hiss; its voice sounds like two
        rough stones being scraped together. It hisses for a few
        moments, its gravelly voice rising and falling.",
208     "The creature snarls. \"NOTHING to sssay to you, do I.\" The
        fiend's eyes narrow to slits. \"If sssstay, your warm blood will
        cover the sssstones.\"\"",
209     "The creature roars, then it launches itself at you!"
210 ]
211 },
212 {
213     "Id": 13,
214     "HeroSpeech": [
215         "\"Greetings.\"\"",
216         "\"I would speak with you for a moment.\"\"",
217         "\"Calm yourself! I just want to talk to you.\"\"",
218         "\"Uh... what?\"",
219         "\"I just wanted to ask you some questions...\"",
220     ],
221     "CharacterSpeech": [
222         "This black-scaled fiend towers to a height of eight feet - its
        great height, however, is offset by its thin, snake-like frame. A
        long prehensile tail drags behind it, and its leathery wings
        are hooked behind its back. A strong vinegary smell emanates
        from the fiend... as well as a certain amount of heat. It seems
        to be ignoring you.",
223         "The creature slowly turns its head down to look at you. Its scaled
        forehead wrinkles into a frown, then it opens its mouth, giving
        a low, rasping hiss. You notice that the heat radiating from the
        creature begins to rise.",
224         "The creature opens its mouth, displaying a row of blackened fangs.
        Fire begins to dance around the shoulders and arms of the
        creature as it gives a long, low hiss.",
225         "The creature speaks in a rasping hiss; its voice sounds like two
        rough stones being scraped together. It hisses for a few
        moments, its gravelly voice rising and falling.",
226         "The creature snarls. \"NOTHING to sssay to you, do I.\" The
        fiend's eyes narrow to slits. \"If sssstay, your warm blood will
        cover the sssstones.\"\"",
227         "The creature roars, then it launches itself at you!"
228     ]
229 }
230 ]

```

Листинг А.2: Файл abishab.json

ПРИЛОЖЕНИЕ Б. ИСХОДНЫЙ КОД ОБРАБОТКИ DNDD

```
1  """
2  This script processes a dataset of Dungeons & Dragons (D&D) dialogues.
3
4  Example:
5      $ python prepare.py --subsets all --generate_descriptions
6      --description_file descriptions.csv --limit_dialogues 25
7  """
8
9  from datetime import datetime
10 import random
11 import requests
12 from transformers import LlamaTokenizer, AutoTokenizer
13
14 from dialogue_data import (
15     collect_and_prepare_dialogue_data,
16 )
17
18 from descriptions import (
19     generate_descriptions,
20     build_dataset,
21     generate_file_paths,
22     save_dataset_subsets,
23     add_descriptions_to_dataset,
24 )
25
26 from arg_parser import create_arg_parser
27
28 def main(args):
29     data_directory = "DNDD_ver0.5"
30     execution_timestamp = datetime.now().strftime("%Y-%m-%d-%H-%M%S")
31     dnd_dataset = collect_and_prepare_dialogue_data(data_directory,
32                                                     args.limit_dialogues)
33
34     if args.generate_descriptions:
35         generate_descriptions(dnd_dataset, tokenizer, execution_timestamp,
36                               args.model_server_url)
37
38     if args.description_file:
39         dnd_dataset = add_descriptions_to_dataset(dnd_dataset,
40                                                   args.description_file)
41
42     if args.build_final:
43         t5_tokenizer = AutoTokenizer.from_pretrained("google/flan-t5-xl")
```

```

38     final_dataset = build_dataset(dnd_dataset.to_pandas(), t5_tokenizer)
39     save_filepath =
40         f"dndd-max_d{args.limit_dialogues}-{execution_timestamp}.parquet"
41     final_dataset.to_parquet(save_filepath)
42     print(f"Saved to {save_filepath}")
43
44     subset_map = generate_file_paths(execution_timestamp, args.limit_dialogues)
45     save_dataset_subsets(dnd_dataset, args.subsets, subset_map)
46
47 if __name__ == "__main__":
48     random.seed(42)
49     parser = create_arg_parser()
50     args = parser.parse_args()
51
52     if isinstance(args.subsets, str):
53         subsets = [args.subsets]
54         args.subsets = subsets
55
56     if args.generate_descriptions:
57         tokenizer = LlamaTokenizer.from_pretrained(args.llama_base_model)
58         try:
59             status_code = requests.get(args.model_server_url).status_code
60             if status_code != 200:
61                 raise Exception(f"Model server returned status code {status_code}")
62         except requests.exceptions.RequestException as ex:
63             print(f"Could not connect to the model server: {ex}")
64             raise ex
65
66     main(args)

```

Листинг Б.1: Файл prepare.py

```

1 import argparse
2
3
4 def create_arg_parser():
5     parser = argparse.ArgumentParser(
6         description="Process subsets of DNDD (Dungeon & Dragons Dialogues) dataset"
7     )
8     parser.add_argument(
9         "--subsets",
10        nargs="+",
11        required=False,
12        default="all",

```



```

1 import requests
2 from typing import Dict, Tuple, List
3 from tqdm import tqdm
4 from datasets import Dataset
5 from transformers import LlamaTokenizer, PreTrainedTokenizer
6 import pandas as pd
7
8
9 from utils import (
10     format_dialogue_history,
11     format_prompt,
12     tokenize_check_overflow,
13     extract_text,
14     default_text,
15 )
16
17
18 def generate_descriptions(
19     dnd_dataset: Dataset,
20     tokenizer: LlamaTokenizer,
21     execution_timestamp: str,
22     model_server_url: str,
23 ) -> None:
24     """
25     Generate descriptions for NPCs based on their dialogues in the given
26     dataset.
27
28     Parameters
29     -----
30     dnd_dataset : 'Dataset'
31         The dataset containing NPC dialogues.
32     tokenizer : 'LlamaTokenizer'
33         The tokenizer for text encoding.
34     execution_timestamp : 'str'
35         The timestamp for execution.
36     model_server_url : 'str'
37         The URL of the model server for generating descriptions.
38     """
39
40     grouped_by_filename: pd.DataFrame = (
41         dnd_dataset.to_pandas().groupby("filename").agg({"npc_turns": list,
42                                                         "player_turns": list}))
43
44     # Instruction text for the model
45     instruction_text = "Create the personality of a single NPC in DnD style,
46                        based on the provided example dialogue in JSON format. Answer in format

```

```

        Name/Alignment/Description/Flaw/Motivation/Personality_in_a_list_format_
        written_in_third_person." # noqa: E501
45 header_text = "NPC-turns:_"
46
47 instruction_len = len(tokenizer.tokenize(instruction_text))
48 header_len = len(tokenizer.tokenize(header_text))
49
50 for filename, dialogues in tqdm(grouped_by_filename["npc_turns"].items(),
    "Generating_data"):
51     dialogue_turns = process_dialogues(dialogues, tokenizer,
        instruction_len, header_len)
52
53     input_text = header_text + str(dialogue_turns)
54     response = make_prediction(
55         model_server_url,
56         instruction_text=instruction_text,
57         input_text=input_text,
58     )
59
60     generated_description = response["data"][0]
61     # Replacing newline characters with "p" to avoid corrupting CSV file
62     generated_description = generated_description.replace("\n", "p")
63     description_filename = f"descriptions-{execution_timestamp}.csv"
64     with open(description_filename, mode="a", encoding="utf-8") as file:
65         file.write(f"{filename},{generated_description}\n")
66
67
68 def make_prediction(
69     model_server_url: str,
70     instruction_text: str,
71     input_text: str,
72     temperature: float = 0.1,
73     top_p: float = 0.2,
74     top_k: int = 100,
75     num_beams: int = 1,
76     max_new_tokens: int = 512,
77     streaming_opt: bool = False,
78 ) -> dict:
79     """
80     Make a prediction using the API endpoint.
81
82     Parameters
83     -----
84     model_server_url : 'str'
85         The URL of the model server.
86     instruction_text : 'str'
87         Instruction text to LLM.
88     input_text : 'str'

```

```

89         Input text containing example NPC dialogues.
90     temperature : 'float', default=0.1
91         Sampling temperature.
92     top_p : 'float', default=0.2
93         Top p sampling value.
94     top_k : 'int', default=100
95         Top k sampling value.
96     num_beams : 'int', default=1
97         Number of beams for beam search.
98     max_new_tokens : 'int', default=512
99         Maximum number of new tokens for the output.
100    streaming_opt : 'bool', default=False
101        Option for streaming LLM output.
102
103    Returns
104    -----
105    dict
106        The prediction response.
107    """
108
109    params = [
110        instruction_text,
111        input_text,
112        temperature,
113        top_p,
114        top_k,
115        num_beams,
116        max_new_tokens,
117        streaming_opt,
118    ]
119
120    response = requests.post(
121        f"{model_server_url}/run/predict",
122        json={"data": params},
123    ).json()
124
125    return response
126
127
128    def build_dataset(dndd_df: pd.DataFrame, tokenizer: PreTrainedTokenizer) ->
    Dataset:
129        """
130        Builds a training dataset from the provided DNDD dataset.
131
132        Parameters
133        -----
134        dndd_df : 'pd.DataFrame'
135            The DNDD dataset DataFrame.

```

```

136     tokenizer : 'PreTrainedTokenizer'
137         The tokenizer used for tokenization.
138
139     Returns
140     -----
141     dict
142         A dictionary containing the 'source' and 'target' lists representing
143         the training dataset.
144     """
145
146     dataset_dict = {"source": [], "target": []}
147
148     for npc_data in tqdm(dnidd_df.itertuples(), "Processing dataset"):
149         dialogue_history = []
150         query = "START_DIALOGUE"
151
152         total_turns = len(npc_data.player_turns) + len(npc_data.npc_turns)
153         for turn_index in range(total_turns):
154             if turn_index % 2 == 0:
155                 target = npc_data.npc_turns[turn_index // 2]
156
157                 formatted_history = (
158                     format_dialogue_history(dialogue_history, npc_data.game)
159                     if dialogue_history
160                     else "EMPTY"
161                 )
162                 npc_prompt = format_prompt(npc_data, formatted_history, query)
163                 formatted_history, dialogue_history = tokenize_check_overflow(
164                     tokenizer,
165                     npc_prompt,
166                     formatted_history,
167                     dialogue_history,
168                     npc_data.game,
169                 )
170
171                 if npc_data.game == "pst":
172                     if query != "START_DIALOGUE":
173                         query = extract_text(query, default_text("Player"))
174                         target = extract_text(target, default_text("NPC"))
175
176                 npc_prompt = format_prompt(npc_data, formatted_history, query)
177                 dataset_dict["source"].append(npc_prompt)
178                 dataset_dict["target"].append(target)
179             else:
180                 dialogue_history.append(query)
181                 dialogue_history.append(target)
182                 query = npc_data.player_turns[turn_index // 2]

```

```

183     return Dataset.from_dict(dataset_dict)
184
185
186 def process_dialogues(
187     dialogues: List[List[str]],
188     tokenizer: LlamaTokenizer,
189     instruction_len: int,
190     header_len: int,
191 ) -> List[str]:
192     """
193     Process dialogues by removing duplicates and ensuring the length of
194     tokenized text is within limit.
195
196     Parameters
197     -----
198     dialogues : 'List[List[str]]'
199         List of dialogues, each dialogue is a list of turns.
200     tokenizer : 'LlamaTokenizer'
201         Tokenizer to be used.
202     instruction_len : 'int'
203         Length of instruction text.
204     header_len : 'int'
205         Length of header text.
206
207     Returns
208     -----
209     'List[str]'
210         Processed dialogue turns.
211     """
212
213     dialogue_turns: List[str] = []
214     for dialogue in dialogues:
215         for turn in dialogue:
216             dialogue_turns.append(turn)
217             # Removing any duplicate turns from the dialogue
218             dialogue_turns = list(set(dialogue_turns))
219
220             # Checking if the length of the tokenized dialogue_turns and
221             # instruction texts are within the limit
222             prompt_len = len(tokenizer.tokenize(str(dialogue_turns))) +
223                 instruction_len + header_len
224             if prompt_len > 500:
225                 print(prompt_len)
226                 dialogue_turns = dialogue_turns[:-1]
227                 break
228             else:
229                 continue
230         break

```

```

228     return dialogue_turns
229
230
231 def generate_file_paths(
232     execution_timestamp: str, limit_dialogues: int
233 ) -> Dict[str, Tuple[str, str]]:
234     """
235     Generates file paths for subsets of a dataset based on the execution
236     timestamp and limit of dialogues.
237
238     Parameters
239     -----
240     execution_timestamp : 'str'
241         The timestamp of the execution.
242     limit_dialogues : 'int'
243         The maximum number of dialogues allowed in the subsets.
244
245     Returns
246     -----
247     'dict'
248         A dictionary mapping subset names to their corresponding file paths.
249     """
250     file_prefix = "data/dnodd_subset_"
251     file_suffix = f"_{execution_timestamp}_max-d_{limit_dialogues}.parquet"
252     subset_map = {
253         "all": ("", f"{file_prefix}all{file_suffix}"),
254         "bg1": ("bg1", f"{file_prefix}bg1{file_suffix}"),
255         "bg2": ("bg2", f"{file_prefix}bg2{file_suffix}"),
256         "id1": ("id1", f"{file_prefix}id1{file_suffix}"),
257         "pst": ("pst", f"{file_prefix}pst{file_suffix}"),
258     }
259     return subset_map
260
261
262 def save_dataset_subsets(
263     dnd_dataset: Dataset, subsets: List[str], subset_map: Dict[str, Tuple[str,
264         str]]
265 ) -> None:
266     """
267     Saves subsets of a dataset based on specified subsets and their
268     corresponding paths.
269
270     Parameters
271     -----
272     dnd_dataset : 'Dataset'
273         The dataset to save subsets from.
274     subsets : 'List[str]'

```

```

273         A list of subset names to save.
274 subset_map : 'Dict[str, Tuple[str, str]]'
275         A dictionary mapping subset names to their corresponding paths.
276         """
277
278     for subset in subsets:
279         subset_prefix, subset_file_path = subset_map[subset]
280         subset_dndd = dnd_dataset.filter(lambda example:
281             example["game"].startswith(subset_prefix))
282         subset_dndd.to_parquet(subset_file_path)
283         print(f"Saved to {subset_file_path}")
284
285 def add_descriptions_to_dataset(dnd_dataset: Dataset, description_file: str) ->
    Dataset:
286     """
287     Adds descriptions to a dataset by merging it with a description file.
288
289     Parameters
290     -----
291     dnd_dataset : 'Dataset'
292         The dataset to which descriptions will be added.
293     description_file : 'str'
294         The path to the description file.
295
296     Returns
297     -----
298     'Dataset'
299         The updated dataset with descriptions.
300     """
301
302     dndd_df = dnd_dataset.to_pandas()
303     desc_df = pd.read_csv(description_file, sep="|")
304     dndd_df_merged = pd.merge(dndd_df, desc_df, on="filename")
305     dnd_dataset = Dataset.from_pandas(dndd_df_merged)
306     return dnd_dataset

```

Листинг Б.3: Файл descriptions.py

```

1 import json
2 import os
3 import random
4 from typing import Union
5 from datasets import Dataset
6 from tqdm import tqdm
7
8
9 def identify_game(dir: str) -> Union[str, None]:

```

```

10     """
11     Identify the game based on the directory name.
12
13     Parameters
14     -----
15     dir : 'str'
16         The directory name.
17
18     Returns
19     -----
20     'Union[str, None]'
21         The game identifier.
22     """
23     game_identifiers = ["pst", "idl", "bg1", "bg2"]
24
25     for game in game_identifiers:
26         if game in dir:
27             return game
28
29     return None
30
31
32 def load_dialogues_from_file(path: str, limit: Union[int, None] = None) -> list:
33     """
34     Load dialogues from a file.
35
36     Parameters
37     -----
38     path : 'str'
39         The path of the file.
40     limit : 'Union[int, None]', default=None
41         The maximum number of dialogues to load.
42
43     Returns
44     -----
45     content:
46         The list of dialogues.
47     """
48
49     with open(path) as file:
50         content = json.load(file)
51     if limit:
52         content = random.sample(content, limit)
53     return content
54
55
56 def collect_and_prepare_dialogue_data(data_directory: str, limit: Union[int,
None]) -> Dataset:

```



```

57     """
58     Collects and prepares dialogue data from multiple files within a directory.
59     The collected data is converted into a Hugging Face Dataset object.
60
61     Parameters
62     -----
63     data_directory : 'str'
64         The base directory containing the files to read data from.
65     limit : 'Union[int, None]'
66         The maximum number of dialogues to load, or None for no limit.
67
68     Returns
69     -----
70     'Dataset'
71         A Hugging Face Dataset object containing the collected dialogue data.
72     """
73
74     dialogue_data = []
75     for directory in os.listdir(data_directory):
76         files = os.listdir(os.path.join(data_directory, directory))
77         game = identify_game(directory)
78         for filename in tqdm(files, f"Processing files in {directory}"):
79             dialogues = load_dialogues_from_file(
80                 os.path.join(data_directory, directory, filename), limit
81             )
82             for dialogue in dialogues:
83                 dialogue["filename"] = filename
84                 dialogue["game"] = game
85                 dialogue_data.append(dialogue)
86
87     dnd_dataset = Dataset.from_list(dialogue_data)
88     dnd_dataset = dnd_dataset.rename_columns(
89         {"HeroSpeech": "player_turns", "CharacterSpeech": "npc_turns"}
90     )
91     dnd_dataset = dnd_dataset.remove_columns("Id")
92     return dnd_dataset

```

Листинг Б.4: Файл dialogue_data.py

```

1  import re
2  from typing import List, Tuple
3  import pandas as pd
4  from transformers import PreTrainedTokenizer
5
6
7  def format_dialogue_history(dialogue_history: List[str], game_type: str) -> str:
8      """
9      Formats the dialogue history into a readable format.

```

```

10
11     Parameters
12     -----
13     dialogue_history : 'List[str]'
14         A list containing the dialogue history. Each item is a dialogue string.
15     game_type : 'str'
16         A string representing the type of the game. If 'pst', special
17         formatting is applied.
18
19     Returns
20     -----
21     'str'
22         The formatted dialogue history. Each turn is on a new line with the
23         format 'Speaker: Dialogue turn'.
24
25     """
26     formatted_history = ""
27     for turn_index in range(len(dialogue_history)):
28         speaker = "Player" if turn_index % 2 == 0 else "NPC"
29         dialogue_turn = dialogue_history[turn_index]
30         if game_type == "pst" and dialogue_turn != "START_DIALOGUE":
31             dialogue_turn = dialogue_turn.replace("\\r", "").replace("\\n", "")
32             extracted_text = re.findall('"(^")*"', dialogue_turn)
33             extracted_text = "".join(extracted_text) if extracted_text else
34                 default_text(speaker)
35             formatted_history += f"{speaker}:_{extracted_text}\\n"
36         else:
37             formatted_history += f"{speaker}:_{dialogue_turn}\\n"
38     return formatted_history
39
40
41 def format_prompt(npc_data: pd.Series, current_history: str, query: str) -> str:
42     npc_prompt = f"""Below is the definition of in-game NPC.
43     NPC Name: {npc_data['name']}
44     Alignment: {npc_data['alignment']}
45     Description: {npc_data['description']}
46     Personality traits: {npc_data['personality']}
47     Flaws: {npc_data['flaw']}
48     Motivation: {npc_data['motivation']}
49
50     Dialogue history:
51     {current_history}
52     Player query: {query}
53
54     Respond to player's query based on defined NPC: """
55     return npc_prompt
56
57 def tokenize_check_overflow(

```

```

55     tokenizer: PreTrainedTokenizer,
56     npc_prompt: str,
57     current_history: str,
58     dialogue_history: List[str],
59     game: str,
60 ) -> Tuple[str, List[str]]:
61     """
62     Truncates the dialogue history to avoid tokenization overflow.
63
64     Parameters
65     -----
66     tokenizer : 'PreTrainedTokenizer'
67         The tokenizer object used for tokenization.
68     npc_prompt : 'str'
69         The NPC prompt or instruction text.
70     current_history : 'str'
71         The current dialogue history.
72     dialogue_history : 'List[str]'
73         The list of previous dialogue turns.
74     game : 'str'
75         The game identifier.
76
77     Returns
78     -----
79     'Tuple[str, List[str]]'
80         A tuple containing the updated current history and dialogue history.
81     """
82
83     prompt_tokens = tokenizer.tokenize(npc_prompt)
84     history_tokens = tokenizer.tokenize(current_history)
85     total_tokens = len(prompt_tokens) + len(history_tokens)
86     while total_tokens > 1024:
87         dialogue_history = dialogue_history[2:]
88         current_history = format_dialogue_history(dialogue_history, game)
89         history_tokens = tokenizer.tokenize(current_history)
90         total_tokens = len(prompt_tokens) + len(history_tokens)
91
92     return current_history, dialogue_history
93
94
95 def extract_text(dialogue, default_text):
96     extracted_text = re.findall('"(^[^"]*)" ', dialogue)
97     return "".join(extracted_text) if extracted_text else default_text
98
99
100 def default_text(speaker: str):

```

101

```
return "Ignore." if speaker == "Player" else "That NPC seems to be ignoring you."
```

Листинг Б.5: Файл `utils.py`

ПРИЛОЖЕНИЕ В. ПРИМЕР ДИАЛОГА

```
1 Below is the definition of in-game NPC.
2 NPC Name: Saablic Tan
3 Alignment: Neutral
4 Description: A tall, gaunt figure with a long, white beard and a hooded cloak.
5 Personality traits: Overconfidence
6 Flaws: To protect his creations from harm
7 Motivation: Saablic is a proud and confident individual, but he is also a bit
   arrogant and overconfident. He is willing to take risks and is not afraid to
   speak his mind. He is also very protective of his creations and will do
   anything to protect them.
8
9 Dialogue history:
10 Player: START DIALOGUE
11 NPC: Proceed... no further, traveler, as... I would... speak with you.
12 Player: I'm sorry, but I really must be on my way.
13 NPC: Know this... traveler. Without... my knowledge... your continued
   existence... within this world... will be limited.
14 Player: All right, I'm listening.
15 NPC: My name... is... was Saablic... Tan. Of my... mistakes... one grew
   tired... used my precious... magics to make... that which... I am. Having...
   much confusion as... days move on. Must... mm... tell you I... am frightened.
16
17 Player query: Why are you frightened?
18
19 Respond to player's query based on defined NPC:
20 ANSWER: Orog that... roam these passages... my passages... are my... creation.
   They... have much contempt... for me. I cannot... leave. My form... my
   home... punishment for my... ambition. I... derived pleasure... for altering
   against... their will. I have... much regret.
```

Листинг В.1: Пример диалога